

2. del

1. Pricakovana vrednost slučajne spremenljivke (matematično upanje)

- primer: npr. igralna kocka (3.5) ali binomska (np)

- $X \sim \begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} \end{pmatrix}$
- $E(X) = \sum_{i=1}^6 x_i \cdot p_i = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + \dots + 6 \cdot \frac{1}{6} = 3.5$

Porazdelitev	E(X)
$B(p)$	p
$B(n, p)$	np
$G(p)$	$\frac{1}{p}$
$P(n, p)$	$\frac{n}{p}$
$H(R, B, n)$	$\frac{nR}{R+B}$
$E([a, b])$	$\frac{a+b}{2}$
$P(\lambda)$	λ
$\text{Exp}(\lambda)$	$\frac{1}{\lambda}$
$\Gamma(n, \lambda)$	$\frac{n}{\lambda}$
$N(\mu, \sigma)$	μ
$\chi^2(n)$	n

- motivacija za definicijo (utezeno povprečje), tj. tezisce

- povprečje vrednosti diskretne spremenljivke (verjetnost · vrednost)
- utezeno povprečje: $k_1 + \dots + k_m = N$, $f_i = \frac{k_i}{N}$

$$\bar{x} = \frac{x_1 k_1 + \dots + x_m k_m}{N} = x_1 f_1 + \dots + x_m f_m$$

- predstavlja μ pri CLI

$$E(X) = \sum_{i=1}^n x_i \cdot p_i$$

- $P(X = a) = 1 \Rightarrow E(X) = a$

- definicija za diskretne slučajne spremenljivke (kdaj obstaja)
 - diskretna slučajna spremenljivka je slučajna spremenljivka, ki ima stevno zalogo vrednosti
 - $E(X) = \sum_{i=1}^n x_i \cdot p_i$
 - **pogoj** $\sum_{i=1}^n |x_i| \cdot p_i < \infty$
 - Slučajna spremenljivka X ima pričakovano vrednost, ko ga ima slučajna sp. $|X|$. Očitno velja $|E(X)| \leq E(|X|)$.
- definicija za zvezne slučajne spremenljivke (kdaj obstaja)
 - zvezna slučajna spremenljivka je slučajna spremenljivka ki lahko zavzameo katerokoli vrednost iz nekega intervala
 - $E(X) = \int_{-\infty}^{\infty} x \cdot p_X(x) dx$
 - **pogoj:** $\int_{-\infty}^{\infty} |x| p_X(x) dx < \infty$
- primer slučajne spremenljivke za katero ne obstaja $E(X)$
 - $X \sim p(x) = \frac{1}{\pi(1+x^2)}$ **Cauchyeva porazdelitev**
 - $x_k = (-1)^{k+1} \frac{2^k}{k}$ in $p_k = 2^{-k}$ (primer diskretne ko je $E(X) = \infty$) V tem primeru bi morala biti končna vsota: $s = \frac{1}{1} + \frac{1}{2} + \frac{1}{3} + \dots$, opazimo $\frac{1}{3} + \frac{1}{4} > \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$, ter v splošnem

$$\frac{1}{2^n + 1} + \dots + \frac{1}{2^{n+1}} > \frac{2^n}{2^n + 1} = \frac{1}{2}$$

torej velja $S > \sum_{n=1}^{\infty} \frac{n}{2} \rightarrow$ neskončna vsota.

- lastnosti: linearnost, z dokazom za homogenost
 - **linearnost:** $E(aX + bY) = aE(x) + bE(Y)$
 - **homogenost:** $E(aX) = aE(X)$:
 - Dokaz : homogenost in linearnost **integriranja** ter **vsote** (po definiciji)
 - $\sum_{i=1}^{\infty} a \cdot x_i p_{X_i} + \sum_{i=1}^{\infty} b \cdot y_i p_{Y_i} = a \cdot b \sum_{i=1}^{\infty} x_i p_{X_i} + y_i p_{Y_i}$
 - $E(X)$ je definirana kot povprečje diskretnih spremenljivk, ce vse to pomnozis s konstanto se mnozi tudi povprečje
- Skica dokaz aditivnosti $E(X+Y) = E(X)+E(Y) =$ ali Trditev 7.1:
 $E(|XY|) \leq \sqrt{E(X^2)E(Y^2)}$

$$\begin{aligned}
 E(X + Y) &= E(Z) = \int_{-\infty}^{\infty} z p_z(z) dz \\
 &= \int_{-\infty}^{\infty} z \left(\int_{-\infty}^{\infty} p(x, z - x) \right) dz = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x + y) p(x, y) dx dy \\
 &\quad \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x p(x, y) dx \right) dy + \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} y p(x, y) dx \right) dy
 \end{aligned}$$

$$= \int_{-\infty}^{\infty} xp_X(x)dx + \int_{-\infty}^{\infty} yp_X(y)dy$$

$$= E(X) + E(Y)$$

- lastnosti vsot/integralov

2. Disperzija (razpršenost oz. varianca) slučajne spremenljivke, odklon in standardizacija

- primeri: npr. binomska ($np(1 - p)$), enakomerna ($(b - a)^2/12$)

porazdelitev	D(X)
$B(p)$	$p(1 - p)$
$B(n, p)$	$np(1 - p)$
$G(p)$	$\frac{1-p}{p^2}$
$P(n, p)$	$\frac{n(1-p)}{p^2}$
$H(R, B, n)$	$\frac{nRB \cdot (R+B-n)}{(R+B)^2(R+B-1)}$
$P(\lambda)$	λ
$\text{Exp}(\lambda)$	$\frac{1}{\lambda^2}$
$\Gamma(n, \lambda)$	$\frac{n}{\lambda^2}$
$E([a, b])$	$\frac{(b-a)^2}{12}$
$\chi^2(n)$	$2n$


- definicija s pričakovano vrednostjo in obstoj
 - **Definicija:** $D(X) = E((X - E(X))^2) = E(X^2) - E^2(X)$
 - $D(X) \geq 0$
 - **Pogoj:** nesme biti neskončna
 - $D(aX) = a^2 D(X)$ in $D(x + a) = D(X)$
- $D(X) = 0 \iff X$ je konstanta
 - $D(X) = E((X - E(X))^2) = E((X - X)^2) = E(0) = 0$
 - Torej če je npr $P(X = a) = c$, Bo odklon vseh ostalih posameznih vzorcev od povprečja = 0;
- lastnosti (aditivnost za neodvisni slučajni spremenljivki)
 - Aditivnost disperzije: $D(X + Y) = D(X) + D(Y) + 2\text{Cov}(X, Y)$
 - če sta X in Y neodvisni: $D(X + Y) = D(X) + D(Y)$
- Standardizacija, slučajne spremenljivke in njena pričakovana vrednost oz. odklon
 - Slučajno spremenljivko X **standardiziramo** s transformacijo

$$X_s = \frac{X - \mu}{\sigma}$$

- $E(X) = \mu$ in $D(X) = \sigma^2$
- **Velja:**
 - $E(X_s) = E\left(\frac{X-\mu}{\sigma}\right) = \frac{E(X-\mu)}{\sigma} = \frac{\mu-\mu}{\sigma} = 0$
 - $D(X_s) = D\left(\frac{X-\mu}{\sigma}\right) = \frac{D(X-\mu)}{\sigma^2} = \frac{\sigma^2+0}{\sigma^2} = 1$
- Standardizacija slučajne spremenljivke povzroči da vsaka spr. enako vpliva na pričakovano vrednost (npr. ce smo neke rezultate zmerili z različnimi merili, to nam pomaga za primerjavo različnih tipov spremenljivk)
- Skica dokaza zveze "kosinusni izrek"
 - $D(X + Y) = D(X) + D(Y) + 2Cov(X, Y) \sim (x + y)^2 = x^2 + y^2 + 2\cos\alpha$
 - analogija: Disperzijo bi lako primerjali s tipicnim geometrijskim kosinusnim izrekom. Ko sta si stranici pravokotni se izraz izracuna neodvisno od $\cos(90) = 0$. Ce pogledamo pri disperziji, ko sta si spremenljivki nedovisni je njuna kovarianca $Cov(X, Y) = 0$.

3. Korelacija in kovarianca

- meri algebraicno povezanost dveh številskih slučajnih spremenljivk
 - predstavlja mero povezanosti med dvema spremenljivkama
 - os y predstavlja slučajno spremenljivko Y
 - os x predstavlja slučajno spremenljivko X



Scribbr

- definicija kovariance in njen obstoj (CS $E(|XY|) \leq \sqrt{E(X^2)E(Y^2)}$)
 - **Kovarianca** $Cov(X, Y) = E((X - E(X)) \cdot (Y - E(Y))) = E(XY) - E(X)E(Y)$
 - $|Cov(X, Y)| \leq \sqrt{D(X)D(Y)} = \sigma_X \sigma_Y$
 - spremenljivki za katere velja da:
 - $Cov(X, Y) \neq 0$ sta **korelirani**
 - $Cov(X, Y) > 0 \rightarrow X \uparrow Y \uparrow$ (pozitivno korelirani)
 - $Cov(X, Y) < 0 \rightarrow X \uparrow Y \downarrow$ (negativno korelirani)
 - $Cov(X, Y) = 0$ sta **nekorelirani**
 - **Primer** $X \equiv$ telesna visina osebe, $Y \equiv$ teza osebe
 - X in Y sta korelirani (pozitivno)
- lastnosti korelacije
 - Ce sta slučajni spremenljivki X in Y neodvisni $\rightarrow E(XY) = E(X)E(Y) \rightarrow Cov(X, Y) = 0$

- definicij korelacijskega koeficienta, vedno na $[-1, 1]$
 - Korelacijski koeficient vpeljemo zato, ker je moc povzezanosti med dvema s.s. tezko ocentit preko kovariance, zato jo delimo s obema std. odklonoma
 - $r(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)} = \frac{E(XY) - E(X)E(Y)}{\sqrt{E(X^2) - E^2(X)} \cdot \sqrt{E(Y^2) - E^2(Y)}}$
 - $r(X, Y) = 0 \Leftrightarrow X$ in Y nekorelirani
 - $r(X, Y) = \pm 1 \Leftrightarrow X$ in Y sta v linearni zvezi
- kdaj lahko zakljucimo linearno odvisnost
 - Dve slucajni spremenljivki sta **linearno odvisni** ce lahko eno zapisemo kot linearno funkcijo druge \rightarrow korelacijski koeficient med njima bo 1 ali -1.
- Ali lahko izracunamo korelacijo iz disperzij (tj. $D(X)$, $D(Y)$ in $D(X+Y)$)
 - $D(X + Y) = D(X) + D(Y) + 2\text{Cov}(X, Y)$
- kovariančna matrika
 - Naj bo X stolpcni vektor $X = (X_1, X_2, \dots, X_n)^T$ (kjer so X_i slucajne spremenljivke)
 - Potem definiramo kovariančno matriko K_{XX} , (i, j) -ti element je (kovarianca):
 - $K_{X_i X_j} = \text{cov}[X_i, X_j] = E[(X_i - E[X_i])(X_j - E[X_j])]$
 - Kovariančna matrika je **simetricna**
 - Diagonalne vrednosti so **disperzije**

$$K_{X_i X_i} = E((X_i - E(X_i))(X_i - E(X_i))) = E((X_i - E(X_i))^2) = D(X_i)$$
- povezava z regresijsko premico
 - $K_{YX} K_{XX}^{-1}$ je matrika regresijskih koeficientov

4. Slucajni vektorji 2D, 3D, nD

- definicija slucajnega vektorja (primer)
 - Slucajni vektor je n-terica slucajnih spremenljiv $X = (X_1, \dots, X_n)$
 - Primer slucajni vektor $X = (X_1, X_2)$:
 - X_1 stevilo metov ko pade sestica, pri 3 metih kocke
 - X_2 stevilo metov ko pade stevilo manjse od 3, pri 3 metih kocke
- definicija porazdelitvene funkcije (primer)
 - $F(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$
 - Primer za metanje kock
 - $F_{X,Y}(x, y) = P(X \leq x, Y \leq y) = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} p_{ij} \cdot 0/1$ (1 ce je $i \leq x$ in $j \leq y$ 0 sicer)
 - Za zvezni vektor uporabimo integrale
 - $F_{X,Y}(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^x \int_{-\infty}^y p_{X,Y}(x, y) dx dy$
- verjetnostna in kontingencna tabela, verjetnostna funkcija (primer)
 - **verjetnostna tabela**

X, Y	y_1	y_2	\dots	y_m	X
x_1	p_{11}	p_{12}	\dots	p_{1m}	p_1
x_2	p_{21}	p_{22}	\dots	p_{2m}	p_2
\dots	\dots	\dots	\dots	\dots	\dots
x_n	p_{n1}	p_{n2}	\dots	p_{nm}	p_n
Y	q_1	q_2	\dots	q_m	1

- kjer:
 - $P(X = x_i, Y = y_j) = p_{ij}$
 - $P(X = x_i) = p_i$, **robna porazdelitev** za X
 - $P(Y = y_i) = q_i$, **robna porazdelitev** za Y
- **kontingencna tabela** (modelira nakup avtomobila)

starost	>20	<20	sum
kupil avtomobil	80	20	100
ni kupil	100	50	150
sum	180	70	250

- gostota verjetnosti (primer)
 - funkciji $p_{X,Y}$ pravimo (dvorazsezna) gostota verjetnosti (določa vektor zveznih spremenljivk)
 - npr: $p_{X,Y}(x, y) = \frac{1}{4}$ z zalogo vrednosti $x \in [0, 2], y \in [0, 2]$
- robne porazdelitvene funkcije
 - Funkciji $F_i(x_i) = F(\infty, \dots, \infty, x_i, \infty, \dots, \infty)$ pravimo **robna porazdelitvena funkcija** spremenljivke X_i
 - Npr za diskretne
 - $P(X = x_i) = \sum_{j=1}^{\infty} p_{ji}$
 - $P(Y = y_i) = \sum_{j=1}^{\infty} p_{ij}$
- Ali se da iz verjetnostne funkcije slučajnega vektorja ugotoviti neodvisnost njegovih komponent?
 - **DA**, npr za diskretni vektor:
 - $\forall x, y : P(X = x, Y = y) = P(X = x)P(Y = y)$
 - npr, za zvezni vektor
 - $\forall x, y, X \leq x \wedge Y \leq y : p_{X,Y}(x, y) = p_X(x)p_Y(y)$
- zveza med gostoto verjetnosti in porazdelitveno funkcijo
 - za dve spremenljivki (na n spremenljivk trivialen prehod):
 - $F_{X,Y}(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^x \int_{-\infty}^y p_{X,Y}(x, y) dx dy$
- definicija kvadranta in izpeljava formule pravokotnik
 - Naj bo $A(x, y) = \{(u, v) \in \mathbb{R}^2 : u \leq x \wedge v \leq y\}$ (levi spodnji kvadrant glede na (x, y))
 - Naj porazdelitvena funkcija opisuje verjetnost da je slučajna točka (X, Y) v množici $A(x, y)$

$$F(x, y) = p(X \leq x, Y \leq y) = P(X, Y) \in A(x, y)$$

- Tedaj je verjetnost da je slučajna točka (X,Y) v pravokotniku $(a, b] \times (c, d]$ enaka:

$$P(X, Y) \in (a, b] \times (c, d] = F(b, d) - F(a, d) - F(b, c) + F(a, c)$$

- neodvisnost
 - diskretne: $P(X = x) \cdot P(Y = y) = P(X = x, Y = y)$
 - zvezne: $P_{X,Y}(X, Y) = P_X(X) * P_Y(Y)$

5. Polinomska porazdelitev

- primeri
 - Imamo volitve z 3 izbirami (A,B,C). Kandidat A prejme 20% glasov, B 30%, C 50% glasov. Če so glasovalci izbrani randomy, kaksna je verjetnost da bomo izmed 6 izbranih izbrali natanko enega volivca za kandidata A, dva za B in tri za C.

$$X \sim P(6; 0.2, 0.3, 0.5)$$

$$P(A = 1, B = 2, C = 3) = \frac{6!}{1!2!3!} (0.2^1)(0.3^2)(0.5^3)$$

- Iz kupa igralnih kart (52) na slepo izberemo eno karto in jo nato vrnemo nazaj. Postopek ponovimo 5-krat. Kolikсна je verjetnost da bomo videli dvakrat srce, po enkrat pa pika kriza in karo

$$X \sim P(5, 0.25, 0.25, 0.25, 0.25)$$

$$P(X_1 = 2, X_2 = 1, X_3 = 1, X_4 = 1) = \frac{5!}{2!1!1!1!} 0.25^2 0.25^1 0.25^1 0.25^1 = 0.05859$$

- definicija
 - Polinomska porazdelitev $\sim P(n; p_1, \dots, p_r)$ je določena s predpisom
 - $P(X_1 = k_1, \dots, X_r = k_r) = \frac{n!}{k_1! \dots k_r!} p_1^{k_1} \dots p_r^{k_r}$

- zaloga vrednosti

$$\begin{aligned} \circ \sum_{i=1}^r p_i &= 1 \\ \circ \sum_{i=1}^r k_i &= n \end{aligned}$$

- verjetnostna funkcija (zapisi p_i, j, \dots, k)
 - Polinomska porazdelitev $\sim P(n; p_1, \dots, p_r)$
 - $\sum p_i = 1, \sum k_i = n$
 - spremenljivke X_i opisujejo število pojavitev rezultata i
 - $P(X_1 = k_1, \dots, X_r = k_r) = \frac{n!}{k_1! \dots k_r!} p_1^{k_1} \dots p_r^{k_r}$
- povezava z binomsko
 - je posplošitev binomske porazdelitve
 - za $r=2$ dobimo binomsko spremenljivko $B(n, p) = P(n, p, q)$
- pričakovana vrednost in disperzija
 - $E(X_i) = np_i$
 - $D(X_i) = np_i(1 - p_i)$

6. Funkcije slučajnih spremenljivk

- primeri enostavnih funkcij

- Imamo $X \sim \begin{pmatrix} -1 & 0 & 1 \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{6} \end{pmatrix}$
- Potem $5X \sim \begin{pmatrix} -5 & 0 & 5 \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{6} \end{pmatrix}$
- Imamo podano porazdelitveno shemo

Y, X	0	1	2	X
0	$\frac{2}{50}$	$\frac{2}{50}$	$\frac{1}{50}$	$\frac{5}{50}$
1	$\frac{6}{50}$	$\frac{6}{50}$	$\frac{3}{50}$	$\frac{15}{50}$
2	$\frac{12}{50}$	$\frac{12}{50}$	$\frac{6}{50}$	$\frac{30}{50}$
Y	$\frac{20}{50}$	$\frac{20}{50}$	$\frac{10}{50}$	1

- $Z = X^2 \sim \begin{pmatrix} 0 & 1 & 4 \\ 0.1 & 0.3 & 0.6 \end{pmatrix}$
- $W = X + Y \sim \begin{pmatrix} 0 & 1 & 2 & 3 & 4 \\ 0.04 & 0.16 & 0.38 & 0.30 & 0.12 \end{pmatrix}$
 - $P(W = 0) = P(X = 0, Y = 0) = 0.04$
 - $P(W = 1) = P(X = 0, Y = 1) + P(X = 1, Y = 0) = 0.16$
 - $P(W = 2) = P(X = 0, Y = 2) + P(X = 1, Y = 1) + P(X = 2, Y = 0) = 0.38$
 - $P(W = 3) = P(X = 1, Y = 2) + P(X = 2, Y = 1) = 0.30$
 - $P(W = 4) = P(X = 2, Y = 2) = 0.12$
- definicija in povezava med ustreznima porazdelitvenima funkcijama
 - naj bo $Y = g(X)$
 - $F_Y(y) = P(g(X) \leq y) = \begin{cases} P(X \leq g^{-1}(y)), & g^{-1} \text{ narascujoca} \\ P(X \geq g^{-1}(y)), & g^{-1} \text{ padajoca} \end{cases}$
 - **Primer:** naj bo $Y = X^2$
 - $P(X^2 \leq y) = P(|X| \leq \sqrt{y}) = P(-\sqrt{y} \leq X \leq \sqrt{y})$
- zveza med gostatami verjetnosti
 - Če je X porazdeljena z zvezno gostoto $p(x)$, je $F_Y(y) = \int_{-\infty}^{f^{-1}(y)} p(x) dx$,
 - in če je f se odvedljiva velja $p_Y(x) = p(f^{-1}(y)) f^{-1}(y)'$
- formula za pričakovano vrednost
 - diskretna:

$$E(f(X)) = \sum_{k=0}^{\infty} f(x_k) \cdot p_k$$

- zvezna

$$E(f(X)) = \int_{-\infty}^{\infty} f(x) \cdot p_X(x) dx$$

- neodvisnost
 - Če so X_1, X_2, \dots, X_n neodvisne standardizirane normalne slučajne spremenljivke, je slučajna spremenljivka $Y = X_1^2 + \dots + X_n^2$ porazdeljena po $\chi^2(n)$
- izpeljava zveze med $N(0, 1)$ in $\chi^2(1)$
 - Naj bo X standardizirana normalna spremenljivka z $p_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$
 - nastavimo $Y = X^2$
 - $g^{-1}(x) = \sqrt{x}$
 - $\frac{dg^{-1}}{dx} = \frac{1}{2} x^{-\frac{1}{2}}$
 - $p_Y(x) = p_X(g^{-1}(x)) \cdot \frac{dg^{-1}}{dx} = \frac{1}{\sqrt{2\pi}} e^{-\frac{x}{2}} \cdot \frac{1}{2} x^{-\frac{1}{2}} = \frac{1}{\sqrt{2\pi x}} e^{-\frac{x}{2}}$
 - Dobili smo $\chi^2(1)$
 - $X_i \sim N(0, 1)$
 - $\chi^2(k) = X_1^2 + \dots + X_k^2$

7. Funkcije slučajnih vektorjev

- primer
 - Izračun pričakovane vrednosti ($E(X)$)
- definicija
 - Naj bo $f : (x, y) \rightarrow (u, v)$ transformacija slučajnega vektorja (X, Y) v slučajni vektor (U, V) določena z zvezama $U = u(X, Y)$ in $V = v(X, Y)$. Porazdelitveni zakon za nov slučajni vektor (U, V) je
 - $F_{U,V}(u, v) = P(U < u, V < v) = P((U, V) \in A(u, v)) = P(X, Y \in f^{-1}(A(u, v)))$
- definicija konvolucije
 - Definiramo $Z = X + Y$, kjer je (X, Y) zvezno porazdeljen slučajni vektor z gostoto $p(x, y)$ verjetnostna funkcija (diskretni)
 - $F_Z(z) = P(Z \leq z) = P(X + Y \leq z) = \int \int_{x+y \leq z} p(x, y) dx dy = \int_{-\infty}^{\infty} dx \int_{-\infty}^{z-x} p(x, y) dy$
 - za slučajni dobimo gostoto verjetnosti:

$$p_Z(z) = \int_{-\infty}^{\infty} f_{XY}(x, z-x) dx$$

- za diskretni pa dobimo

$$P(Z = z) = \sum_{k=-\infty}^{\infty} P(X = k) P(Y = z - k)$$

- ce sta neodvisni pa

$$p_Z(z) = \int_{-\infty}^{\infty} p_X(x) p_Y(z-x) dx$$

- Gostota $p_Z = p_X * p_Y$ je **konvolucija** funkcij p_X in p_Y .
- uporaba za vsoto dveh neodvisnih normalnih porazdelitev
 - $X \sim N(\mu_X, \sigma_X^2)$
 - $Y \sim N(\mu_Y, \sigma_Y^2)$
 - $Z = X + Y \rightarrow Z \sim N(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2)$
- uporaba za vsoto dveh neodvisnih Gama porazdelitev
 - $X \sim \Gamma(n_1, \lambda)$, in $Y \sim \Gamma(n_2, \lambda)$ potem $X + Y \sim \Gamma(n_1 + n_2, \lambda)$
- formula za pričakovano vrednost produkta
 - $E(XY) = E(E(XY|Y))$
 - ce sta neovidsni
 - $E(XY) = E(X) \cdot E(Y)$
- Jacobijeva determinanta in prehod na nove spremenljivke
 - Ce je funkcija f bijektivna z zveznimi parcialnimi odvodi lahko nadaljujemo

$$F_{U,V}(u, v) = \int \int_{A(u,v)} p(x(u, v), y(u, v)) \left| \det \begin{pmatrix} \frac{\partial u}{\partial x} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y} \end{pmatrix} \right| dudv$$

8. Pogojna porazdelitev

- primer za diskretni slučajni vektor
 - Imamo porazdelitveno shemo. Zapiši pogojno verjetnostno porazdelitev slučajne spremenljivke X , glede na pogoj $y=2$

$Y \setminus X$	1	2	3	4	Y
0	0	0.10	0.20	0.10	0.40
1	0.03	0.07	0.10	0.05	0.25
2	0.05	0.10	0.05	0	0.20
3	0	0.10	0.05	0	0.15
X	0.08	0.37	0.40	0.15	1

- Verjetnost v vrstici pri $y = 2$, moramo deliti s $P(Y = 2) = 0.2$

$$X|y = 2 \sim \begin{pmatrix} 1 & 2 & 3 & 4 \\ 0.25 & 0.5 & 0.25 & 0 \end{pmatrix}$$

- definicija v diskretnem primeru in v zveznem primeru
 - diskretni primer:
 - Naj bo B nek mogoč dogodek $P(B) > 0$. Potem lahko vpeljemo **pogojno porazdelitveno funkcijo**:

$$F(x|B) = P(X \leq x|B) = \frac{P(X \leq x, B)}{P(B)}$$

- zvezni primer:
 - Postavimo $B = (y < Y \leq y + h)$ za $h > 0$ in zahtevajmo $P(B) > 0$

$$F_X(x|B) = P(X \leq x|B) = \frac{P(X \leq x, y < Y \leq y+h)}{P(y \leq Y < y+h)} = \frac{F(x, y+h) - F(x, y)}{F_Y(y+h) - F_Y(y)}$$

- pogojna porazdelitvena funkcija v obeh primerih
 - diskretni primer:

$$F_X(x|y_k) = F_X(x|Y = y_k) = P(X \leq x|Y = y_k) = \frac{P(X \leq x, Y = y_k)}{P(Y = y_k)} = \frac{1}{q_k} \sum_{x_i \leq x} p_{ik}$$

- zvezni primer:
 - ce obstaja limita za ($h \rightarrow 0$)

$$F_X(x|y) = F_X(x|Y = y) = \lim_{h \rightarrow 0} \frac{F(x, y+h) - F(x, y)}{F_Y(y+h) - F_Y(y)}$$

- imenujemo jo pogojna porazdelitvena funkcija slučajne spremenljivke X glede na dogodek ($Y=y$)
- izpeljava pogojne verjetnostne funkcija v diskretnem primeru
 - Vpeljimo pogojno verjetnostno funkcijo $p_{i|k} = \frac{p_{ik}}{q_k}$. Tedaj je $F_X(x|y_k) = \sum_{x_i \leq x} p_{i|k}$
- izpeljava pogojne gostote v zveznem primeru
 - Naj bosta gostoti $p(x, y)$ in $p_Y(y) > 0$ zvezni. Tedaj je:

$$F_X(x|y) = \lim_{h \rightarrow 0} \frac{\frac{F(x, y+h) - F(x, y)}{h}}{\frac{F_Y(y+h) - F_Y(y)}{h}} = \frac{\frac{\partial F}{\partial y}(x, y)}{F'_Y(y)} = \frac{1}{p_Y(y)} \int_{-\infty}^x p(u, y) du$$

- primer za zvezni slučajni vektor

9. Momenti in kvantili

- Momenti pokazuje lastnosti vzorca - povprečno vrednost, razprsitev, asimetrijo in sploscenost.
- katere momente poznas

- **Zacetne** (merimo od 0)
 - Consider the following dataset [12 14 14 17 18]
 - Consider alternate dataset

1515151515

(enak prvi moment)

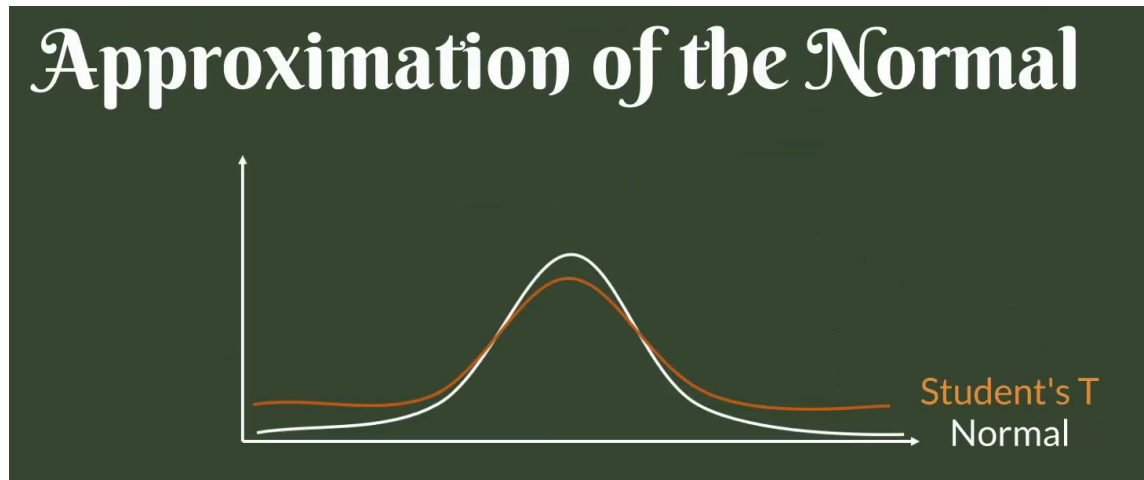
- Each item represents distance from 0
- average distance from zero: $\frac{\sum x_i}{n} \rightarrow$ **prvi moment** = $\mu_1 = 15$ predstavlja **povprecije**
- average square distance from zero : $\frac{\sum x_i^2}{n} \rightarrow$ **drugi moment** = $\mu_2 = 229.8$ (alternate data set ima $\mu_2 = 225$)
- $\frac{\sum x_i^3}{n}$ **tretji moment**
- $\frac{\sum x_i^4}{n}$ **cetrty moment**
- **Centralne** (merimo od sredine)

- average square distance from povprečna vrednost $\frac{\sum(x_i - \mu_1)^2}{n} \rightarrow$ **centriran drugi moment** predstavlja varianco σ^2
- $\frac{\sum(x_i - \mu_1)^3}{n} \rightarrow$ **centriran tretji moment** (asimetrija skewness)
- $\frac{\sum(x_i - \mu_1)^4}{n} \rightarrow$ **centriran četrti moment** (splosčenost, kurtosis)
- **Standardizirane**
 - $\frac{1}{n} \frac{\sum(x - \mu)^3}{\sigma^3}$ (standardiziran tretji moment)
 - $\frac{1}{n} \frac{\sum(x - \mu)^4}{\sigma^4}$ (standardiziran četrti moment)
- definicija momenta reda k glede na točko a
 - Momenti so posplošitev pričakovane vrednosti in disperzije.
 - Momenti reda $k \in \mathbb{N}$ glede na točko $a \in \mathbb{R}$ imenujemo kolicino $m_k(a) = E((X - a)^k)$
 - Moment obstaja, če obstaja pričakovana vrednost, ki ni neskončna $E(|X - a|^k) < \infty$
 - Za $a = 0$ dobimo začetni moment $z_k = m_k(0)$
 - Za $a = E(X)$ dobimo centralni moment $m_k = m_k(E(X))$
- začetni moment, centralni moment
 - začetni moment ko je $a = 0$
 - centralni moment ko je $a =$ povprečna vrednost
- lastnosti
 - Če obstaja centralni moment reda n , potem obstaja vsi momenti reda k , $k \leq n$
 - Če obstaja začetni moment reda n , potem obstajajo tudi centralni momenti reda n za $\forall a \in \mathbb{R}$
 - Če sta X in Y neodvisni velja: $m_3(X + Y) = m_3(X) + m_3(Y)$
- definicija kvantila
 - Kadar spremenljivka nima momentov uporabimo kvantile.
 - Kvantili so "linije" ki razdelijo podatke v skupine enake velikosti
 - Mediana je drugi kvantil (ker polovica podatkov manše polovica večje)
 - Percentili so kvantili ki delijo podatke v 100 skupine enake velikosti
- povezava z inverzom porazdelitvene funkcije
 - TODO

10. Studentova porazdelitev t-test

- why (<https://www.youtube.com/watch?v=32CuxWdOlow>)
- Primer1
 - Povprečna teža 20 studentov je bila 165lbs z vzorcnim standardnim odklonom 4.5. Konstruiraj 95% interval zaupanja za populacijsko povprečje.
 - $\bar{x} = 165$, $n = 20$, $s = 4.5$
 - Ker **nimamo standardnega odklona populacije** σ , ne moremo izračunati normalne porazdelitve, ampak uporabimo studentovo
 - Poleg tega imamo tudi $n \leq 20$ (za normalno rabimo $n \geq 30$)
 - $\mu \rightarrow \bar{x} \pm t_{n-1, \alpha/2}$
 - $n - 1 =$ degrees of freedom = 19
 - $\frac{\alpha}{2} = \frac{0.05}{2} = 0.025$
 - $t_{19, 0.025} =$ pogledamo v tabeli = 2.093

- $\mu \rightarrow 165 \pm 2.093\left(\frac{4.5}{\sqrt{20}}\right) = 165 \pm 2.106$
- Dobili smo 95% interval zaupanja $I_\mu = [162.894, 167.106]$
 - z 95% lahko recemo da je povprečna teža v tem intervalu
- Kako lahko pridemo do te porazdelitve?
 - Uporablja se kadar imamo na voljo majhno število podatkov, in je približek normalne porazdelitve
 - Pridemo preko naslednjega obrazca:
- $$t_{n-1,\alpha} = \frac{\bar{x} - \mu}{s/\sqrt{n}}$$
- Podobna normalni z “debelimi kraki” (večja dispersija - manj podatkov - manjša zanesljivost)
- za $n > 30$ je že skor enaka z-statistiki (normalni porazdelitvi)
- $Z_X = \mathbb{R}$



- gostota verjetnosti

$$p(x) = \frac{\left(1 + \frac{x^2}{n-1}\right)^{-\frac{n}{2}}}{\sqrt{n-1} B\left(\frac{n-1}{2}, \frac{1}{2}\right)}$$

- definicija beta funkcije

$$B(x, y) = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x+y)} = B(y, x)$$

- posebne vrednosti beta funkcije

$$B\left(\frac{1}{2}, \frac{1}{2}\right) = \pi$$

$$B(n_1, n_2) = \frac{(m-1)!(n-1)!}{(m+n-1)!} \text{ za } n_1, n_2 \in \mathbb{N}$$

- katero porazdelitev dobimo za eno prostostno stopnjo in katero, če je število prostostnih stopenj dovolj veliko
 - **ena prostostna stopnja:** Cauchyeva porazdelitev
 - **dovolj veliko število prostostnih stopenj:** Normalna porazdelitev

11. Fisherjeva porazdelitev f-test

- kako lahko pridemo do te porazdelitve primer

Recimo da imamo dve populaciji. Populacijo1 bomo primerjali z Populacijo2. Recimo da naredimo **IQ** test na obeh populacijah. Na vzorcih iz obeh populacij izračunamo vzorčno povprečje ter (vzorčni odklon) s_1^2 ter s_2^2 - Primerjali

bomo dva vzorcna odklona - **Testna statistika** (Fisherjeva) je $F = \frac{S_1^2}{S_2^2} \cdot s_1^2$ dobimo iz n vzorcev 1. populacije - s_2^2

dobimo iz m vzorcev 2. populacije - F-distribution, parametri - $F(n, m) = \frac{\chi^2(n)/n}{\chi^2(m)/m}$ - n prostostne

stopnje prve χ^2 spremenljivke - m prostostne stopnje druge χ^2 spremenljivke - $Z_F = \mathbb{R}^+$ - oblika odvisna od prostostnih stopenj obeh vzorcov - definicija - verjetnostna funkcija

$$p(x) = \frac{m^{\frac{3}{2}} n^{\frac{n}{2}}}{B(\frac{m}{2}, \frac{n}{2})} \cdot \frac{x^{\frac{(m-2)}{2}}}{(n + mx)^{\frac{m+n}{2}}}$$

- beta
funkcije

$$B(x, y) = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x + y)} = B(y, x)$$

$$B(\frac{1}{2}, \frac{1}{2}) = \pi$$

- Primer statistike, ki se porazdeljuje po Fisherjevo - F-test za hipoteze o enakosti varianc v dveh normalno porazdeljenih statističnih populacijah in v regresijski analizi. - se kaksne

lastnosti fisherjeve porazdelitve - Za $U \sim F(m, n)$ je $\frac{1}{U} \sim F(n, m)$ - Za $U \sim t(n)$ je

$U^2 \sim F(1, n)$

Statisticni parameter	enacba
Pricakovana vrednost μ	$\frac{m}{m-2}, m > 2$
Modus	$\frac{n-2}{n} \cdot \frac{m}{m+2}$
varianca	$\frac{2m^2 \cdot (n+m-2)}{n(m-2)^2(m-4)}$